


Chunking ist Teil des Modells

Semantische Segmentierung großer ALS-Punktwolken mit Point Transformer V3

Silvio Leon Echsle · Masterarbeit, TU Berlin · Portfolio- und Interviewpräsentation · 15. September 2026



DALES-Szene 5175_54395 · 12,1 Mio. Punkte · Ground Truth

Warum 12 Millionen Punkte globale Attention sprengen

$N \approx 12.000.000$

$N^2 = 144 \text{ Billionen}$

$\approx 2,3 \text{ PB}$

Punkte pro DALES-Szene · etwa 500 × 500 × 230 m

Naive globale Attention


- 288 TB je Attention-Kopf in FP16
- 2,3 PB bei acht Köpfen
- nur die Attention-Matrix, ohne Aktivierungen, Gradienten oder Optimizer

Massiv verteilte Spezialinfrastruktur könnte Teile dieser Last verteilen. Für einen reproduzierbaren Versuchsaufbau auf normaler Forschungs- oder Industriehardware ist eine globale 12-Millionen-Punkte-Sicht nicht praktikabel.

Die Alternative ist nicht blindes Subsampling: Semantische Vorhersagen brauchen lokale Umgebungsgeometrie. Gleichzeitig würden gerade die seltenen Klassen zuerst ausgedünnt.

Punktpaare bei globaler Attention

Attention-Werte für acht Köpfe in FP16



97,9 % der Punkte liegen in drei Klassen. poles: 0,07 %. Blindes Downsampling trifft die seltenen Klassen zuerst.

Deshalb: lokal kohärent zerlegen, lokal vorhersagen und anschließend eine konsistente Sicht auf die Gesamtszene rekonstruieren.

Forschungsfrage und Versuchsaufbau

Wie beeinflussen Zerlegungs- und Rekombinationsstrategien die Genauigkeit und Recheneffizienz transformerbasierter semantischer Segmentierung großräumiger urbaner ALS-Punktwolken?

1 Zerlegung

- Flächenraster
- Z-Kurven-Sortierung
- K-D-Baum
- rekursive Flächenteilung
- Kugel-Nachbarschaften
- Zylinder-Nachbarschaften

6 Varianten



2 PTv3

intern unverändert

- Datenanreicherungen
- lokale Attention
- raumfüllende Kurven

fest gehalten



3 Vorhersagen

Koordinaten und
Klassenwahrscheinlichkeiten
je Chunk



4 Rekombination

- Mehrheitsentscheid
- Abstandsgewichtung
- Konfidenzgewichtung
- Abstand × Konfidenz

4 Varianten









5 Gesamtszene


Genauigkeit, Laufzeit
und Speicher

Für alle 24 Kombinationen gleich: Datensatz und Split · Punktbudget und Überlappungsziel · Trainingsrezept · interne Datenanreicherungen · interne Lokalisationsdarstellung des Modells

2D overview of all chunkers using the repository implementations




Overlap: mehr Kontext gegen mehr Arbeit



Gemessen, nicht angenommen


Alle sechs Chunker teilen dasselbe nominale Overlap-Ziel von 10 %. Der **tatsächliche** Anteil mehrfach abgedeckter Punkte reicht von



Ein eigenes Prüfskript misst die echten Schnittmengen zwischen den Chunks einer Szene. Gleiche Vorgabe, völlig verschiedene Geometrie.

Rekombination: wer gewinnt den Streit?

Derselbe Punkt, drei Chunks



gestrichelt: Abstand zum jeweiligen Chunkzentrum

Was die drei lokal sagen

Chunk A → **Gebäude**

$p = 0,91$ $d = \text{klein}$
tief im Chunk, voller Kontext

Chunk B → **Vegetation**

$p = 0,52$ $d = \text{groß}$
am Rand, Kontext abgeschnitten

Chunk C → **Gebäude**

$p = 0,74$ $d = \text{mittel}$
teilweiser Kontext

Beispielwerte zur Erklärung der Regeln —
gemessen wurden bis zu 12 Stimmen für einen Punkt.

Vier Regeln, das Ergebnis entscheiden

Mehrheitsentscheid

jede Stimme zählt gleich · 2 zu 1

Gebäude

Abstandsgewichtung

Gauß-Gewicht nach Abstand zum Zentrum

Gebäude

Konfidenzgewichtung

Gewicht = maximale Klassenwahrscheinlichkeit

Gebäude

Kombinierte Gewichtung

beide Gewichte multipliziert

Gebäude

Gemessen über alle sechs Chunker:

Konfidenzgewichtung: 0,4096 mIoU

Mehrheitsentscheid: 0,3242 · Unterschied: 0,085


Was dabei herauskommt

Szenen-mIoU: jede Zerlegung mal jede Rekombination

xy	0.2523	0.2729	0.3112	0.2776
morton	0.2576	0.2716	0.2766	0.2725
kdtree	0.5523	0.5549	0.5549	0.5552
rand_knn	0.2848	0.3673	0.4779	0.3857
rand_cyl	0.3678	0.3277	0.4555	0.3410
bisect_xy	0.2306	0.3169	0.3817	0.3305
	majority	distance	confidence	distance_conf.

bestes Feld

Die Merge-Regel zählt genau dort, wo der Chunker Overlap erzeugt



0,5552

bestes Szenen-mIoU: `kdtree` + `distance_confidence`

0,4096

`confidence` ist im Mittel die beste Merge-Regel


+0,193

was die Merge-Regel bei `rand_knn` bewegt


Wo die Fehler tatsächlich sitzen

Szene 5175_54395, bestes Setup — oben die ganze Szene, unten ein Ausschnitt daraus, zweimal anders eingefärbt


Ground Truth ganze Szene




Vorhersage ganze Szene · kdtree + distance_confidence · 0,6160 mIoU




Fehler Ausschnitt · rot = falsch, blau = richtig



Support derselbe Ausschnitt · grün = von mehr Chunks abgedeckt




Qualität hat einen Preis



Der Modelldurchsatz bleibt mit **0,275 bis 0,285 Chunks pro Sekunde** praktisch konstant. Die Laufzeitunterschiede entstehen durch Chunkzahl, Redundanz und Trainingsdauer.

Das System hinter dem Experiment



Zwischen den Schichten liegen Dateien, kein Prozesszustand.

Deshalb ist jede Stufe einzeln wiederholbar, cachebar und parallelisierbar — und jede Metrik bis zum Rohdatensatz zurückverfolgbar.

Der Stack, den das gebraucht hat

Daten	DALES	PLY	NumPy			
Zerlegung	Python 3.10	SciPy	Numba	FAISS		
Lernen	PyTorch 2.5	CUDA 12.4	Pointcept	PTv3		
Rekombination & Auswertung	NumPy	Matplotlib				
Steuerung	Jupyter	Git	Bash	PowerShell		
Produkt	Flask	JavaScript	HTML	CSS	REST	pytest
Kommunikation	LaTeX	AsciiDoc	Reveal.js			

Vom Forschungscode zum Werkzeug

Vorher — im Thesis-Fork

- Punktidentität über gerundete Koordinaten
- Chunk-Verzeichnisse mit `.npy`
- Keine Integritätsprüfung
- Läuft nur mit Pointcept und PyTorch
- Bedienung über ein Notebook

Nachher — als Bibliothek

- Explizite, geprüfte `source_id` je Punkt
- Versioniertes ZIP mit Manifest
- SHA-256 je Chunk, Prüfung beim Merge
- **Nur NumPy** — Pointcept ist keine Abhängigkeit mehr
- 106 grüne Tests, HTTP-API, eigene Lizenz

Gleiche Algorithmen, anderer Vertrag: Aus Code, der im Experimentkontext richtig war, wurde Code, der auch außerhalb hält.

Was ich daraus mitnehme

Fachlich

- Zerlegung und Rekombination sind **methodische Variablen**, keine Implementierungsdetails
- Der **K-D-Baum** ist der stärkste Chunker und gewinnt schon vor der Fusion
- Die **Konfidenzgewichtung** ist die beste Standardregel zur Rekombination
- Rekombination zahlt sich **proportional zur erzeugten Redundanz** aus

Übertragbar

- Eine Ressourcengrenze ist eine **messbare Bedingung**, kein Hindernis
- Persistente Stufengrenzen machen eine Pipeline wiederholbar und parallelisierbar
- Ein Datenvertrag mit stabilen IDs und Prüfsummen ist der Unterschied zwischen Forschungscode und Software
- Ein Ergebnis ist erst fertig, wenn es jemand anderes **bedienen** kann

Grenzen, die ich nennen muss: ein Backbone, ein Datensatz, ein Punktbudget, ein Overlap-Ziel, keine Seed-Wiederholungen. Der Vergleich ist deskriptiv, nicht statistisch abgesichert.

Technischer Ausblick: Chunking nach Informationsbedarf

Nächste Zerlegungsstrategien

- **Dichteadaptiv:** Radius und Punktbudget an lokale Dichte koppeln
- **Strukturgeführt:** geometrische Kerne mit DBSCAN, HDBSCAN oder OPTICS finden und bis zum Budget erweitern
- **Randbewusst:** Überlappung gezielt dort erhöhen, wo Kontext fehlt
- **Hilbert-Sortierung:** räumliche Nachbarschaft besser erhalten als mit dem Morton-Code

Danach systematisch prüfen

- Überlappung als Parameterstudie statt fester 10 Prozent
- Konfidenzen kalibrieren und Wahrscheinlichkeiten direkt mitteln
- Randpunkte bereits in der Verlustfunktion anders gewichten
- Übertragbarkeit auf weitere Datensätze und Backbones testen

Die Ergebnisse sprechen für adaptive Chunker: Rechenaufwand dort investieren, wo zusätzlicher Kontext die Entscheidung tatsächlich verbessert.

Demo

1
Punktwolke laden

2
Metadaten prüfen

3
Strategie wählen


4
Chunken

5
Chunks ansehen

6
Rekonstruieren

Demo starten

Erwartetes Ergebnis: 2.304 Punkte → **16 Chunks bei Redundanz 1,0000** → wieder **exakt 2.304 Punkte**. Die Rekonstruktion läuft über die stabilen `source_id`, nicht über gerundete Koordinaten.



Backup

Folien für Nachfragen — nicht Teil des Vortrags.

Warum PTv3?

- Aktuellste Generation der Point-Transformer-Reihe, 2024
- Serialisierte Attention über raumfüllende Kurven statt globaler Nachbarschaftssuche
- Starke Kontextabhängigkeit — genau die Eigenschaft, die auf Zerlegung reagiert
- Ein schwächeres Kontextmodell hätte den untersuchten Effekt kleiner erscheinen lassen
- Bewusst außerhalb: Superpoint- und Supertoken-Ansätze, weil sie Repräsentation und Lokalisierungsmechanismus gleichzeitig ändern und die Effekte vermischen würden

Warum DALES?

- Städtisches ALS, punktweise annotiert, öffentlicher Benchmark mit offiziellem Split
- Szenengröße macht Skalierbarkeit zu einem echten, nicht theoretischen Problem
- Starke Klassen-Imbalance: 97,9 % in drei Klassen
- Nur Geometrie + Reflektanz — die Zerlegung entscheidet, wie viel Kontext bleibt
- Externe Vergleichbarkeit über die publizierten Baselines des Originalpapiers

Die sechs Chunker im Detail

Strategie	Prinzip	Aktive Parameter
xy	Reguläres achsparalleles Gitter in der Ebene; provisorische Fenster werden rekursiv geteilt, bis das Budget hält	point_max=45000 , distance_space=xy
morton	Quantisierung, Bit-Interleaving zu einem Morton-Schlüssel, Sortierung, zusammenhängende Blöcke	morton_points=45000 , morton_overlap=0.1 , morton_dims=xy
kdtree	Rekursive achsparallele Median-Teilung in der Ebene bis zum Budget	kdtree_point_max=45000 , kdtree_overlap=0.1 , overlap_mode=fill_to_budget
rand_knn	Seed-Punkt, k nächste Nachbarn im vollen 3D-Raum; nächster Seed als nächster unbearbeiteter Kandidat außerhalb der aktuellen Stütze	rand_knn_max_points=45000 , backend=faiss_cpu , distance_space=xyz
rand_cyl	Wie rand_knn , aber Ranking nur in x-y; die volle vertikale Ausdehnung bleibt erhalten	rand_cyl_max_points=45000 , backend=faiss_cpu , distance_space=xy
bisect_xy	Rekursive Halbierung entlang der jeweils längeren Horizontalachse, mit Überlappung an der Schnittlinie	bisect_max_points=45000 , bisect_overlap=0.1 , bisect_fast_numba=True

Für unterfüllte Chunks gibt es eine **chunker-konsistente Auffüllregel**: Gitter-, k-d-Tree- und Bisektions-Blätter werden mit den nächstliegenden Punkten außerhalb ihres Stützbereichs aufgefüllt, Morton-Chunks mit benachbarten Positionen in der Morton-Ordnung. Die beiden stochastischen Nachbarschafts-Chunker erzeugen konstruktionsbedingt keine unterfüllten Chunks.

Overlap: wie er implementiert ist

- Gemeinsames nominales Ziel von 10 %, aber **unterschiedliche geometrische Mechanismen**
- `kdtree` und `bisect_xy`: `fill_to_budget` — die Blätter werden über ihre Grenze hinaus bis zum Punktbudget aufgefüllt
- `morton`: `stride_overlap` — die Blöcke werden mit Schrittweite kleiner als Blocklänge gebildet
- `rand_knn` / `rand_cyl`: Der nächste Seed ist der nächstgelegene noch unbearbeitete Kandidat direkt außerhalb der aktuellen Stütze; bereits bearbeitete Punkte dürfen weiterhin als Nachbarn auftauchen. Daraus entsteht ein Frontier-Verlauf mit hohem Overlap
- Gemessene Duplikatanteile: 11,4 % · 46,5 % · 54,4 % · 65,9 % · 89,8 % · 91,3 %
- Maximaler Support je Punkt: bis zu **12** überlappende Vorhersagen bei `rand_knn`

Die Merge-Formeln

Für einen Szenenpunkt u , überdeckt von der Chunkmenge $T(u)$, mit der lokalen Wahrscheinlichkeit p_k aus Chunk t :

- **majority** — $s_k(u) = \sum_t v_k(u, t)$ über One-Hot-Votes. Gleichstand wird deterministisch über den kleinsten Klassenindex aufgelöst.
- **gewichtete Form** — $s_k(u) = (\sum_t w_t \cdot p_k) / (\sum_t w_t)$. Die drei folgenden Regeln unterscheiden sich **nur** in w_t .
- **distance** — $w_t = \exp(-d_t^2 / 2\sigma_t^2)$, wobei d_t der Abstand zum Chunkzentrum ist und σ_t aus der Streuung der Punkt-zu-Zentrum-Abstände desselben Tiles stammt.
- **confidence** — $w_t = m_t^\alpha$ mit $m_t = \max_k p_k$, also der maximalen Klassenwahrscheinlichkeit der lokalen Vorhersage.
- **distance_confidence** — das Produkt beider Gewichte.

Implementiert als **eine** gewichtete Akkumulation über `np.bincount`; die Regel ändert nur das Gewicht. `support_count` fällt dabei als Nebenprodukt ab.

Klassen-Imbalance im Training

- Gewichtete Cross-Entropy mit inverser Frequenzgewichtung: $w_c = \left(\frac{\bar{n} + \epsilon}{n_c + \epsilon} \right)^\gamma$, hier $\epsilon = \gamma = 1$, wobei n_c die Punktzahl der Klasse im Batch und $\bar{n}$ das Mittel über die im Batch vorhandenen Klassen ist
- Die Restklasse `other` wird zusätzlich mit $\beta = 0,2$ heruntergewichtet, danach werden die Gewichte auf Mittelwert eins renormiert
- Loss-Stack: Cross-Entropy **plus** Lovász-Softmax, beide mit Gewicht 1; Focal-Modulation deaktiviert (`focal_gamma = 0`)
- Begründung: Lovász ist ein differenzierbarer IoU-Surrogat und zieht das Training zur Evaluationsmetrik; CE hält die punktwisen Wahrscheinlichkeiten scharf

Hardware und Umgebung

Komponente	Ausstattung
CPU	Dual-Socket Intel Xeon E5-2630 v4, 20 Kerne / 40 Threads, 2,20–3,10 GHz
RAM installiert	≈ 252 GiB
RAM praktisch nutzbar	≈ 48 GB , kein Swap konfiguriert
GPU-Pool im Host	2 × Quadro RTX 6000 (23 GB) · 1 × RTX 5000 (16 GB) · 3 × RTX 4000 (8 GB)
GPUs im Experiment	fixe 2 × 23 GB
Speicher	SSD, 400 GB + 500 GB RAID1 plus weitere SSDs
Software	Python 3.10, PyTorch 2.5, CUDA 12.4, Conda-Env <code>pointcept-cu124</code>


Die nutzbaren 48 GB — nicht die installierten 252 — sind der Grund für den RAM-Guard und für die Entscheidung, das Chunking als persistenten Vorverarbeitungslauf zu externalisieren.

Trainingskonfiguration im Detail

Einstellung	Wert
Batch-Größe (effektiv)	2 (2)
Optimierer	AdamW, lr $5 \cdot 10^{-4}$, Block-LR-Ratio 0,1
Scheduler	ReduceLROnPlateau, Faktor 0,5, Threshold 10^{-3} , EMA α 0,2
Holdout	16 % der Trainings-Chunks, Seed 42
Early Stopping	Patience 8, Min-Delta 10^{-3} , max. 30 Epochen
Mixed Precision	an · Gradient Clipping 20,0
Loss	CE + Lovász, inverse Frequenz, <code>other</code> -Downweight 0,2
Eingabe	x, y, z, Reflektanz
Test	13-View Test-Time-Augmentation
Modellprofil	<code>minimal/minimal</code> , Backbone-Out 32


Tatsächlich trainierte Epochen bis zum Early Stop: `xy` 6 · `morton` 9 · `kdtree` 11 · `rand_knn` 12 · `rand_cyl` 14 · `bisect_xy` 11 — **alle sechs Läufe endeten durch Early Stopping**, keiner lief die 30 Epochen aus.

Ergebnisse pro Klasse



Die drei dominanten Klassen sind gelöst. `poles` erreicht 0,516 bei 0,07 % Punktanteil — das ist bemerkenswert. `trucks` bei 0,014 ist es nicht: Nur die beiden Nachbarschafts-Chunker erreichen dort überhaupt Werte über null (0,099 und 0,123).


Chunk-Ebene gegen Szenen-Ebene



`kdtree` verliert durch die Rekombination minimal ($-0,012$), weil es schon auf Chunk-Ebene sehr stark ist. Die Nachbarschafts-Chunker gewinnen jeweils rund $0,14$ — sie liefern komplementäre Belege, die erst die Fusion nutzbar macht. `morton` gewinnt $0,008$, weil es kaum Overlap erzeugt.

Parallelisierung: was gemessen ist

Wo sich die Pipeline wirklich parallelisieren lässt



Der Preprocessing-Speedup endet bei 1,88-fach, **weil der Pilot nur zwei Szenen umfasste** und die Szene die Arbeitseinheit ist — bei vier Workern bleibt nichts mehr zu verteilen. Die Rekombination mit vier unabhängigen Szenen erreicht 3,63-fach bei 91 % paralleler Effizienz. In den finalen Läufen ist die Rekombination bewusst sequenziell geblieben, weil ihr Anteil an der Gesamtlaufzeit gering war.

Was sonst noch nicht funktioniert hat

- **Feste planare Fenster garantieren kein Punktbudget.** In dichten Regionen überschreitet ein `xy`-Fenster die 45.000 Punkte. Lösung: Fenster gelten nur als provisorische Stütze und werden rekursiv entlang alternierender Achsen geteilt.
- **Morton brachte PTv3s Serialisierung an eine Tiefengrenze.** Langgestreckte Validierungs-Chunks liefen über. Lösung: gröbere Quantisierung **nur im Validierungspfad**.
- **Die OOM-Sonde für das Punktbudget scheiterte an sich selbst.** Das aufbewahrte Ergebnis zeigt `oom: false`, `return_code: 1` — ein Konfigurationsfehler, kein Speicherproblem. Daraus wird bewusst keine Zahl verwendet.
- **Cluster-basierte Chunker kamen nicht ins Experiment.** k-Medoids, CLARANS, DIANA, CURE und dichte-basierte Varianten sind implementiert bzw. als Platzhalter reserviert, aber ausdrücklich ausgeschlossen. Der Anhang listet 19 Kandidaten mit Rolle, erwartetem Vorteil und Implementierungsrisiko.
- **Graph-CRF-Glättung** ist implementiert, war in den finalen Läufen aber deaktiviert (`crf_iters = 0`) und wird deshalb nicht als Ergebnis gezeigt.

Was von mir ist und was nicht

Bereich	Umfang	Herkunft
Die sechs Chunker (<code>preprocess_dales_ply.py</code>)	≈ 3.100 Zeilen	neu angelegt
Die vier Merge-Regeln (<code>merge_tiles.py</code>)	291 Zeilen	neu angelegt
Validierung, Benchmarks, Ressourcenschutz, Visualisierung	33 Skripte	neu angelegt
Experimentsteuerung	10.088 Zeilen	neu angelegt
Scheduler-Integration	+441 / −5	Upstream erweitert
Trainings-Hooks, Checkpoint-Politik	+413 / −43	Upstream erweitert
Trainingsloop, Holdout, Early Stopping	+366 / −18	Upstream erweitert
Loss-Gewichtung	+218 / −29	Upstream erweitert
Tile-Export für die Rekombination	+101 / −16	Upstream erweitert
PTv3-Backbone	+21 / −3	praktisch unverändert Upstream
CUDA-Kernel (<code>libs/point*</code>)	103 Dateien	reiner Upstream
Dockerfile-Generator, Formatter-CI	2 Dateien	reiner Upstream (Pointcept-Autoren)

Ermittelt über `git log --author --diff-filter=A` und `--numstat` . Der Einsatz generativer KI-Werkzeuge als Hilfsmittel ist in der Arbeit selbst deklariert.

Ausblick

- **Parameterstudie** statt fester Einstellung, vor allem für den Overlap; auf der Ordnungsseite Hilbert- statt Morton-Kurve
- **Struktur-geführtes Chunking**: erst semantische Kerne über Clustering finden, dann bis zum Budget aufweiten — HDBSCAN, DBSCAN und OPTICS sind die plausibelsten Kandidaten
- **Kalibrierte Confidence-Fusion** über Temperature Scaling; vorher fehlt noch die einfachste Baseline — reines Mitteln der Wahrscheinlichkeitsvektoren
- **Randgewichtung schon im Loss**: Punkte nahe dem Chunkzentrum stärker gewichten, weil Randpunkte in überlappungsreichen Chunkern eine zweite Chance bekommen
- **Systems-Seite**: Chunk-Index von Tile-Export trennen, Rekombination parallelisieren, Lineage-basiertes Wiederverwenden von Zwischenergebnissen
- **Transfer** des Protokolls auf andere Datensätze und Backbones