


Große 3D-Daten für KI beherrschbar machen


Vom 3D-Scan zur belastbaren Daten- und KI-Pipeline

Silvio Leon Echsle · Masterarbeit, TU Berlin · Bewerbung Data & AI Engineer · 15. September 2026




Ein Scanner macht die reale Welt messbar

ALS




aus der Luft Drohne oder Flugzeug

TLS



vom Boden stationärer Scanner

MLS




in Bewegung Fahrzeug oder Roboter

Ein 3D-Scanner tastet seine Umgebung ab. Millionen Messpunkte ergeben gemeinsam ein digitales 3D-Abbild.

Nutzen Vermessung, Dokumentation und industrielle Prüfung

Beispiel: Eine digitalisierte Gasturbine



Welche Punkte gehören zu welchem Bauteil?


Bauteile erkennen

Soll und Ist vergleichen


Inspektion unterstützen

Digitalen Zwilling vorbereiten

Die KI gibt jedem Punkt eine Bedeutung



Messpunkte ohne Klassenfarben



Klasse für jeden Punkt

Semantische Segmentierung bedeutet hier: Die KI entscheidet für jeden Punkt, was er darstellt.

Eine ganze Szene passt nicht auf einmal in den Grafikspeicher

≈ **12 Mio.**

Punkte in einer Szene

zu groß für einen Durchlauf

45.000

Punkte je Teilbereich im Experiment

Globale Aufmerksamkeit vergleicht jeden Punkt mit jedem anderen. **144 Billionen Punktpaare**

Sechs Schritte machen große 3D-Daten beherrschbar

1

Daten erfassen

3D-Szene verstehen

2

Daten zerlegen

passende Teilbereiche

3

KI anwenden

Klasse je Punkt

4

Ergebnisse vereinen

Gesamtszene herstellen

5

Qualität messen

faire Kennzahlen


6

Lösung wählen


Zielkonflikte abwägen

Meine Arbeit: die vollständige Daten- und Evaluationspipeline aufbauen und ihre Stellschrauben systematisch vergleichen.


Die Zerlegung entscheidet, welchen Kontext die KI sieht



Dasselbe KI-Modell analysiert jeden Teilbereich



Teilbereiche



Vorhersagen je Punkt

Teilanalysen müssen wieder ein Gesamtbild ergeben



Mehrere lokale Sichtweisen können widersprechen. Eine klare Regel löst den Konflikt reproduzierbar.

Eine automatisierte Pipeline macht 24 Varianten vergleichbar

$$\begin{array}{ccccc} 6 & \times & 4 & = & 24 \\ \text{Zerlegungen} & & \text{Regeln zum Vereinen} & & \text{kontrollierte Varianten} \end{array}$$


Qualität

Wie viele Klassen erkennt die KI?


Laufzeit

Wie lange dauert der gesamte Ablauf?

Ressourcen

Wie viel Speicher und Redundanz entstehen?

Der K-D-Baum liefert in diesem Versuch die beste Qualität



0,5552
beste Qualität

26 h
vollständiger Lauf

Aus dem Experiment entstand eine reproduzierbare Datenpipeline



Technologien nach Aufgabe

Daten	DALES	PLY	NumPy		
Zerlegung	Python 3.10	SciPy	Numba	FAISS	
KI	PyTorch 2.5	CUDA 12.4	Pointcept	PTv3	
Auswertung	NumPy	Matplotlib			
Automatisierung	Jupyter	Git	Bash	pytest	
Produktisierung	Flask	JavaScript	HTML	CSS	REST
Präsentation	LaTeX	AsciiDoc	Reveal.js		

Vom technischen Problem zur belastbaren KI-Lösung

TECHNISCH

mehrere Strategien entwickelt und getestet

METHODISCH

**Qualität und Aufwand reproduzierbar
vergleichbar gemacht**

TRANSFER

**einen skalierbaren Weg vom Datensatz zur
Entscheidung geschaffen**

Diesen Weg möchte ich bei Siemens Energy für industrielle Daten- und KI-Anwendungen weitergehen.

Optional: 75 Sekunden Vorführung

- 1

Punktwolke laden
- 2

Daten prüfen
- 3

Zerlegung wählen
- 4

Teile erzeugen
- 5

Ergebnis prüfen
- 6

Szene herstellen

Vorführung starten

Erwartetes Ergebnis: **2.304 Punkte** werden in **16 Teilbereiche** zerlegt und ohne Verlust wieder zu **2.304 Punkten** zusammengesetzt.



Backup

Backup: Die sechs Zerlegungsmethoden

Flächenraster

regelmäßige Zellen in der Ebene

Z-Kurven-Sortierung

räumliche Reihenfolge

K-D-Baum

rekursive Teilung am Median

Rekursive Flächenteilung

Teilung bis zum Punktbudget

Kugelnachbarschaften

lokale Umgebung um Ankerpunkte

Zylindernachbarschaften

Umgebung über die volle Höhe


Backup: Ergebnisse aller 24 Kombinationen

Szenen-mIoU: jede Zerlegung mal jede Rekombination


xy	0.2523	0.2729	0.3112	0.2776
morton	0.2576	0.2716	0.2766	0.2725
kdtree	0.5523	0.5549	0.5549	0.5552
rand_knn	0.2848	0.3673	0.4779	0.3857
rand_cyl	0.3678	0.3277	0.4555	0.3410
bisect_xy	0.2306	0.3169	0.3817	0.3305
	majority	distance	confidence	distance_conf.

bestes Feld


Backup: Überlappung verändert Kontext und Aufwand



Backup: Qualität und Laufzeit



Backup: Auswahl des Nachbarschaftsverfahrens



Backup: Grenzen der Aussage

- Ein Modelltyp und ein Datensatz
- Ein vollständiger Lauf je Kombination, keine Wiederholung mit mehreren Zufallsstarts
- Vergleich innerhalb des Versuchsaufbaus, kein Anspruch auf allgemeinen Benchmark-Sieg
- Produktisierung und Browserwerkzeug entstanden nach der Masterarbeit